

Activitat 0 — Primer contacte amb les dades i amb R

Matemàtica Aplicada · Part pràctica — Bloc 1: Taules de freqüència

Context: el projecte que farem servir tot el curs

Al llarg d'aquest bloc (i dels següents) treballarem sempre amb el mateix conjunt de dades reals, perquè així podrem anar aplicant cada concepte nou (taules de freqüència, gràfics, mitjana, desviació típica, regressió...) sobre un mateix "repte": **saber si les nits d'estiu són cada cop més calorós a casa nostra.**

Les dades provenen del **Servei Meteorològic de Catalunya (Meteocat)**, de l'estació climàtica de **Nulles/Valls** (comarca de l'Alt Camp), i contenen el registre **diari** de tres variables des de l'1 de gener de 1950 fins avui:

Variable	Nom a l'arxiu	Unitats	Significat
Precipitació acumulada diària	PPT	mm	Quanta pluja ha caigut aquell dia
Temperatura màxima diària	TX	°C	La temperatura més alta que s'ha registrat aquell dia
Temperatura mínima diària	TN	°C	La temperatura més baixa que s'ha registrat aquell dia (normalment de matinada)

A més, cada fila té tres columnes que identifiquen **quan** s'ha pres la dada: ANY, MES i DIA.

Per què ens interessa la TN (temperatura mínima)? Perquè és la que fem servir per definir una **nit tropical**: una nit en què la temperatura no baixa de 20 °C. Passar la nit per sobre de 20 °C dificulta el descans i té efectes reals sobre la salut, per això els serveis meteorològics en porten el compte. Durant el curs construirem, pas a pas, les eines estadístiques necessàries per estudiar com ha evolucionat aquest fenomen a Nulles al llarg de més de 70 anys.

Nota important: hi ha un concepte encara més extrem, la **nit tòrrida** ($TN \geq 25$ °C). A Nulles, en tota la sèrie 1950-2025, **no s'ha donat mai** cap nit tòrrida (la TN més alta registrada a l'estiu és de 24,5 °C). Per això, en tot el material treballarem amb el llindar de **nit tropical (20 °C)**, que sí que és un fenomen que podem observar i mesurar en aquesta estació.

Objectius d'aquesta activitat

En aquesta primera activitat **no calcularem res encara**: l'objectiu és només **familiaritzar-nos amb les dades i amb les dues eines** que farem servir tot el curs (Google Sheets i RStudio), de manera que a partir de l'Activitat 1 ja puguem centrar-nos en l'estadística.

En acabar aquesta activitat hauràs de ser capaç de:

- Importar l'arxiu de dades a Google Sheets i a R sense errors.
- Explicar què representa cada columna del fitxer i de quin **tipus de variable** es tracta (segons el que hem vist al Bloc 1: qualitativa/quantitativa, discreta/contínua).
- Fer servir les primeres ordres de R per mirar les dades: `read.table()`, `head()`, `View()`, `nrow()`, `ncol()`, `str()`.
- Extreure una columna concreta d'una taula de dades en R amb el símbol `$`.

L'arxiu de dades

El fitxer es diu `nulles_dades_climatiques_diaries.txt`. És un arxiu de text amb una peculiaritat important: **les 11 primeres línies no són dades**, sinó una capçalera informativa sobre l'estació:

SERVEI METEOROLÒGIC DE CATALUNYA
Nom de la sèrie: NULLES/VALLS
Comarca: ALT CAMP
Codi sèrie: baic0022d
Variable1: PRECIPITACIÓ ACUMULADA DIÀRIA (PPT, en mm)
Variable2: TEMPERATURA MÀXIMA DIÀRIA (TX, en °C)
Variable3: TEMPERATURA MÍNIMA DIÀRIA (TN, en °C)
X UTM31: 354383 m
Y UTM31: 4572742 m
Z UTM31: 230 m

ANY	MES	DIA	PPT	TX	TN
1950	1	1	0	12.1	5.6
1950	1	2	0	10.6	2.1
...					

La línia 12 (ANY MES DIA PPT TX TN) és la **capçalera de la taula** (el nom de cada columna), i a partir de la línia 13 comencen les dades pròpiament dites, una fila per dia. Les columnes estan separades per **tabulacions** (la tecla de tabulador, no espais ni comes), per això diem que és un arxiu **TSV** (*tab-separated values*), cosí germà del més conegut CSV (*comma-separated values*, separat per comes).

Aquest detall —que les primeres 11 línies no són dades— és el primer que haurem de dir tant a Google Sheets com a R quan els demanem que llegeixin l’arxiu, o la importació sortirà malament.

Pas 1 — Obrir l’arxiu a Google Sheets

1. Crea un full de càlcul nou a Google Sheets.
2. Menú **Arxiu** → **Importa** → **Puja** i selecciona `nulles_dades_climatiques_diaries.txt`.
3. Google Sheets et preguntarà com vols importar-lo. Tria:
 - **Ubicació d’importació:** *Reemplaça el full actual* (o *Insereix un full nou*, com prefereixis).
 - **Tipus de separador:** normalment Sheets detecta automàticament que és una **tabulació**; si no ho fa, selecciona-ho manualment.
4. Un cop importat, veuràs que les **11 primeres files** contenen el text informatiu de la capçalera i que la fila 12 té els noms de columna (ANY, MES, DIA, PPT, TX, TN). Selecciona les files 1 a 11 (clicant als números de fila) i **elimina-les** (botó dret → *Suprimeix les files*), de manera que la fila 1 del full passi a ser ANY MES DIA PPT TX TN i la fila 2 sigui la primera dada (1950, 1, 1...).
5. Congela la primera fila (**Visualització** → **Congela** → **1 fila**) perquè es vegin sempre els noms de columna encara que et desplacis avall.

Al final hauries de tenir un full net, amb capçalera a la fila 1 i dades a partir de la fila 2, amb tantes files com dies té la sèrie (uns 27.700 dies, més de 75 anys de dades!).

Pas 2 — Primer contacte amb RStudio

Si mai has obert RStudio, el primer que veuràs són (normalment) quatre finestres:

Finestra	Per a què serveix
Console (consola)	On escrius ordres i R et respon a l’instant. És com una calculadora molt potent.
Source (editor de script)	On escrius i desa el codi en un arxiu <code>.R</code> , per poder-lo tornar a executar més endavant.
Environment (entorn)	La llista de “coses” (dades, resultats...) que tens guardades en aquell moment.
Files / Plots / Help	Explorador d’arxius, gràfics que generis, i ajuda de les funcions.

Recomanem que **no treballis directament a la consola**, sinó que obris un script nou (**File** → **New File** → **R Script**) i hi vagis escrivint les ordres, perquè així les tens guardades i les pots tornar a executar sense retornar-les a escriure. Per executar una línia del script, la selecciones i prems **Ctrl+Enter** (o el botó “Run”).

📖 Mini manual R — conceptes bàsics abans de començar

- **Funció:** una ordre que fa alguna cosa, amb la forma `nom_funcio(arguments)`. Per exemple, `nrow(dades)` és la funció `nrow` aplicada a l'argument `dades`.
- **Assignació (<-):** a R, per desar un resultat amb un nom, fem servir la fletxa <- (i no el símbol =, encara que també funcioni). Per exemple: `dades <- read.table(...)` vol dir “el resultat de llegir l'arxiu, desa'l amb el nom `dades`”.
- **Objecte:** qualsevol cosa que tingui un nom desat a R (una taula de dades, un número, una llista de valors...). Un cop creat, apareix a la finestra *Environment*.
- **Comentari (#):** tot el que escrius després d'una coixinet # en una línia, R l'ignora. Serveix per anotar-nos què fa el codi.

Pas 3 — Llegir l'arxiu amb R

Escriu al teu script:

```
# Llegim l'arxiu de dades de Nulles.
# skip = 11 -> ens saltem les 11 primeres línies (la capçalera informativa)
# header = TRUE -> la primera línia que Sí llegim conté els noms de columna
# sep = "\t" -> les columnes estan separades per tabulacions
dades <- read.table("nulles_dades_climatiques_diaries.txt",
                    skip = 11, header = TRUE, sep = "\t")
```

Explicació de cada part de la instrucció:

- `read.table(...)`: la funció de R que llegeix un arxiu de text i el converteix en una taula de dades (el que R anomena un *data frame*).
- `"nulles_dades_climatiques_diaries.txt"`: el primer argument, entre cometes perquè és un **text** (el nom de l'arxiu). Ha d'estar a la mateixa carpeta que el teu script, o bé has d'indicar el camí complet.
- `skip = 11`: li diem a R que ignori les 11 primeres línies del fitxer (la capçalera informativa que hem vist abans).
- `header = TRUE`: li diem que, un cop saltades aquestes 11 línies, la **primera línia que trobi** (ANY MES DIA PPT TX TN) s'ha d'interpretar com els noms de les columnes, no com a dades.
- `sep = "\t"`: li indiquem que el caràcter que separa les columnes és una tabulació (s'escriu "\t" a R).
- `dades <-`: guardem el resultat amb el nom `dades`. A partir d'ara, `dades` és la nostra taula sencera, amb totes les files i columnes.

Pas 4 — Explorar la taula

Un cop llegida, mai treballem “a cegues”: sempre val la pena mirar què hem carregat abans de continuar.

```
head(dades)      # mostra les 6 primeres files
View(dades)      # obre la taula en una finestra, com un full de càlcul
nrow(dades)      # quantes files (dies) té la taula
ncol(dades)      # quantes columnes té la taula
str(dades)       # resumeix l'estructura: tipus de cada columna
```

Què fa cada funció:

Funció	Què retorna	Per què és útil
<code>head(dades)</code>	Les primeres 6 files de la taula	Comprovar ràpidament que la lectura ha anat bé (noms de columna correctes, valors amb sentit)
<code>View(dades)</code>	Obre una pestanya nova amb la taula sencera, navegable	Inspeccionar visualment, com si fos un full de càlcul (però només per mirar, no per editar)
<code>nrow(dades)</code>	Un número: el nombre de files	Saber la mida de la mostra (aquí: el nombre de dies registrats)
<code>ncol(dades)</code>	Un número: el nombre de columnes	Saber quantes variables tenim
<code>str(dades)</code>	Un resum tècnic de cada	Detectar si alguna columna s'ha

```
str(dades)
```

columna (nom i tipus: int, num...) llegit malament (per exemple, com a text en lloc de número)

Si tot ha anat bé, `nrow(dades)` t'hauria de donar un valor proper a **27.759** (un per cada dia entre l'1 de gener de 1950 i finals de 2025), i `ncol(dades)` hauria de donar **6**.

Pas 5 — Accedir a una columna concreta: el símbol \$

Sovint no volem tota la taula, sinó només **una columna**. A R, s'hi accedeix amb el símbol \$:

```
dades$TN      # tota la columna de temperatures mínimes
dades$TN[1:10] # només els 10 primers valors d'aquesta columna
mean(dades$TN) # la mitjana de TOTES les temperatures mínimes (hivern inclòs!)
```

Explicació:

- `dades$TN`: agafa la columna `TN` de la taula `dades`. El resultat és una llista de números (a R en diem *vector*), un per cada fila de la taula.
- `dades$TN[1:10]`: els claudàtors [...] serveixen per seleccionar posicions concretes dins d'un vector; `1:10` vol dir “de l'1 al 10”. Així doncs, obtenim només els 10 primers valors.
- `mean(dades$TN)`: la funció `mean()` calcula la mitjana d'un vector de números. Ull: aquí estem fent la mitjana de **totes** les temperatures mínimes de l'any sencer (gener inclòs!), cosa que barreja hivern i estiu. Més endavant (Activitat 2) aprendrem a quedar-nos només amb els mesos d'estiu abans de calcular res.

Pas 6 — I a Google Sheets?

L'equivalent de “mirar les primeres files” a Sheets és tan senzill com desplaçar-te a dalt del full. Per obtenir el nombre de files de dades (equivalent a `nrow()`), pots fer servir la fórmula:

```
=CONTAR(A2:A)
```

Explicació: `CONTAR()` compta quantes cel·les d'un rang contenen un **número**. El rang `A2:A` vol dir “de la cel·la `A2` fins al final de la columna `A`” (suposant que la columna `A` és ANY, i que la fila 1 és la capçalera). El resultat t'hauria de coincidir amb el `nrow(dades)` que has obtingut a R.

Classifica les variables (repàs del Bloc 1)

Abans d'acabar, repassem els tipus de variable (Bloc 1) aplicats a aquest mateix conjunt de dades. Completa la taula:

Variable	Tipus (qualitativa/quantitativa, nominal/ordinal/discreta/contínua)
ANY (any)	
MES (mes, 1-12)	
DIA (dia del mes)	
PPT (precipitació, mm)	
TX (temperatura màxima, °C)	
TN (temperatura mínima, °C)	

Pista: pensa si cada variable resulta de **comptar** (valors aïllats, no té sentit un valor intermedi) o de **mesurar** (en teoria, qualsevol valor decimal és possible dins un interval).

Resum de l'activitat

- Hem importat el mateix conjunt de dades (temperatures i pluviometria diàries de Nulles, 1950-2025) tant a Google Sheets com a R, tenint cura de saltar-nos les 11 línies de capçalera informativa.
- Hem après les primeres funcions de R per explorar una taula de dades: `read.table()`, `head()`, `View()`,

`nrow(), ncol(), str()`.

- Hem après a extreure una columna concreta amb `$` i a seleccionar-ne una part amb `[...]`.
- Hem repassat la classificació de variables del Bloc 1 aplicant-la a un cas real.

Següent pas (Activitat 1): definirem la nostra primera variable pròpia —si una nit és tropical o no— i construirem la nostra primera taula de freqüències amb dades reals.