

Activitat 2 — Filtrar: quedem-nos només amb l'estiu

Matemàtica Aplicada · Part pràctica — Bloc 1: Taules de freqüència

Context

Seguim treballant amb el registre diari de Nulles/Valls (1950–2025) i amb la nostra variable “nit tropical” ($TN \geq 20$ °C), creada a l’Activitat 1. Allà vam detectar un problema: si calculem el percentatge de nits tropicals sobre **l’any sencer**, el resultat queda “diluït” perquè inclou mesos (desembre, gener...) on el fenomen és pràcticament impossible a casa nostra.

La solució és **filtrar**: quedar-nos únicament amb les files que ens interessin, en aquest cas els mesos d’estiu. En aquest projecte definim **estiu** com els mesos de **juny a setembre (mesos 6, 7, 8 i 9)**. Pot semblar una definició una mica més àmplia que l’estiu “oficial” (que a l’hemisferi nord comença el 21 de juny), però inclou el juny sencer perquè és quan comencen a aparèixer les primeres nits tropicals amb regularitat, i deixem fora l’octubre perquè les nits ja solen refrescar-se prou.

Filtrar és una de les operacions més bàsiques —i més utilitzades— en qualsevol anàlisi de dades: gairebé sempre, abans de calcular res, cal decidir *amb quin subconjunt de les dades* farem els càlculs.

Objectius

- Entendre què significa **filtrar** una taula de dades i per què sovint és un pas necessari abans de calcular freqüències, mitjanes, etc.
 - Aprendre a filtrar per **múltiples valors possibles** d’una columna (mes 6, 7, 8 o 9), tant a R (`%in%`) com a Sheets (`FILTRA` amb `+`).
 - Reconstruir la taula de freqüències de “nit tropical” (Activitat 1) però ara **només amb dades d’estiu**, i comparar el resultat.
-

Part A — Treballem amb R

Primer fem tot el recorregut amb **R** (RStudio). A la Part B repetirem les mateixes operacions amb **Google Sheets**.

R · Pas 1 — Filtrar per múltiples mesos

A l'Activitat 1 vam fer servir `subset()` amb una única condició (`ANY == 2020`). Ara necessitem una condició una mica més rica: “el mes és 6, 7, 8, 9”. Podríem escriure-ho amb l'operador “o” (`|`), però R ofereix una eina més còmoda per a aquest cas: l'operador `%in%`.

```
estiu <- subset(dades, MES %in% c(6, 7, 8, 9))
nrow(estiu)
```

Explicació pas a pas:

- `c(6, 7, 8, 9)`: la funció `c()` (de *combine*, “combinar”) crea un **vector**, és a dir, una llista de valors. `c(6, 7, 8, 9)` és el vector amb els quatre mesos d'estiu.
- `MES %in% c(6, 7, 8, 9)`: l'operador `%in%` es llegeix “pertany a”. Per a cada fila, pregunta “el valor de MES d'aquesta fila, és un dels valors de la llista?” i retorna `TRUE` o `FALSE`. És equivalent a escriure `MES == 6 | MES == 7 | MES == 8 | MES == 9`, però molt més curt i llegible.
- `subset(dades, ...)`: com ja sabem, ens quedem només amb les files on la condició és `TRUE`.
- `estiu <-`: guardem el resultat amb un nom nou. A partir d'ara, `estiu` conté només els dies de juny, juliol, agost i setembre, de tots els anys (1950–2025).

Si tot ha anat bé, `nrow(estiu)` t'hauria de donar **9.272** files (76 anys complets × 122 dies d'estiu cadascun, aproximadament).

Mini manual R — per què no fem servir == amb una llista?

Un error molt habitual quan es comença amb R és escriure `MES == c(6, 7, 8, 9)` esperant que funcioni com `%in%`. No ho fa: `==` compara **element a element**, no “pertany a la llista”, i dona resultats incorrectes o avisos d'error estranys. Sempre que vulguis comprovar si un valor és un d'entre diversos possibles, fes servir `%in%`.

R · Pas 2 — Refer la variable “nit tropical” sobre les dades d'estiu

```
estiu$tropical <- estiu$TN >= 20
table(estiu$tropical)
prop.table(table(estiu$tropical))
```

Aquestes línies són exactament les mateixes que a l'Activitat 1, però ara aplicades a `estiu` en lloc de `any2020`: la lògica no canvia, només canvia **el conjunt de dades de partida**. Aquesta és una idea important en programació: un cop tens un procediment que funciona, el pots reaplicar a dades diferents sense reescriure'l des de zero.

Part B — Treballem amb Google Sheets

Ara fem el mateix amb el full de càlcul, partint de les dades que ja vas importar a l'Activitat 0.

Sheets · Pas 1 — Filtrar per múltiples valors: FILTRA

A Sheets, la funció equivalent a `subset()` és `FILTRA`. Per quedar-nos amb els mesos d'estiu (columna B = MES):

```
=FILTRA(A2:F27760; (B2:B27760=6) + (B2:B27760=7) + (B2:B27760=8) + (B2:B27760=9))
```

Explicació:

- `FILTRA(rang; condició)`: retorna només les files del rang on la condició és certa (diferent de zero).
- `A2:F27760`: el rang de dades que volem filtrar (ajusta el número de fila final al nombre real de files del teu full).
- `(B2:B27760=6) + (B2:B27760=7) + (B2:B27760=8) + (B2:B27760=9)`: aquí fem el mateix “truc” `TRUE=1/FALSE=0` que hem vist a R, però en Sheets: cada comparació `(B2:B27760=6)` dona una columna de `VERTADER/FALS` (que Sheets tracta com 1/0), i **sumant-les** amb `+` obtenim un valor diferent de zero (és a dir, “cert” per a `FILTRA`) si el mes és el 6, el 7, el 8 o el 9. Si sumàvem `AND/I` en comptes de `+`, exigiríem que es complissin totes alhora, cosa que mai passaria (un mes no pot ser 6 i 7 a la vegada).

Aquesta fórmula genera automàticament una taula nova amb només les files d'estiu, sense haver de tocar res manualment (a diferència del filtre manual que vam fer servir a l'Activitat 1). Un cop tens aquestes dades filtrades en un rang nou, pots aplicar-hi la mateixa fórmula `SI` i `COMPTA`. `SI` de l'Activitat 1 per reconstruir la taula de nit tropical.

Comparem els resultats: any sencer vs. només estiu

Amb les dades **d'estiu de tota la sèrie (1950–2025)**, la taula de freqüències de “nit tropical” ($n = 9.272$ nits d'estiu) queda:

Nit tropical? (només estiu)	n_i	f_i	f_i (%)
No	8.245	0,889	88,9%
Sí	1.027	0,111	11,1%
Total	9.272	1,00	100%

Interpretació: un 11,1% de les nits d'estiu (juny–setembre) de tota la sèrie 1950–2025 han estat tropicals. Compara aquest valor amb el 5,7% que havíem obtingut a l'Activitat 1 fent servir l'any 2020 sencer (hivern inclòs): el percentatge puja perquè ara el denominador (el “total”) ja no inclou dies on el fenomen és impossible. Aquest és exactament l'efecte que sospitàvem: **filtrar abans de calcular canvia el resultat**, i normalment el fa més representatiu del que volem estudiar de debò.

Per practicar

- Calcula (amb R o Sheets) el percentatge de nits tropicals només per al mes de **juliol** de tota la sèrie. És més alt o més baix que l'11,1% del conjunt juny–setembre? Per què creus que passa això?
 - A R, `estiu$MES` només pot valer 6, 7, 8 o 9 (ja hem filtrat). Comprova-ho amb `table(estiu$MES)`: hauries d'obtenir quatre categories, una per mes.
 - Reflexiona: si volguéssim estudiar les **glàçades** (nits amb $TN \leq 0^\circ\text{C}$) en lloc de les nits tropicals, per quins mesos hauria de filtrar les dades? Escriu la instrucció de R (`%in%`) que ho faria.
-

Resum de l'activitat

- Hem après a **filtrar** una taula de dades per quedar-nos només amb un subconjunt (els mesos d'estiu), amb `%in%` a R i **FILTRA** a Sheets.
- Hem vist que triar bé el conjunt de dades sobre el qual calculem (filtrar abans de calcular) és tan important com el càlcul en si mateix.
- Hem reconstruït la taula de freqüències de “nit tropical” amb dades ja filtrades, i n’hem comparat el resultat amb el de l’Activitat 1.

Següent pas (Activitat 3): la temperatura mínima (TN) és una variable contínua; en lloc de reduir-la a Sí/No, aprendrem a construir-ne una taula de freqüències **amb intervals**, tal com vam veure al Bloc 1 amb l'exemple de les alçades.