

Activitat 9 — Dispersió: rang, variància i desviació típica

Matemàtica Aplicada · Part pràctica — Bloc 4: Mesures de dispersió

Context

A l'Activitat 8 hem dit que un estiu “típic” de la dècada de 2010 té uns 22 nits tropicals. Però dues dècades poden tenir **la mateixa mitjana** i ser molt diferents: en una, tots els estius s'assemblen; en l'altra, uns són freds i uns altres extrems. Una mitjana, sola, **amaga** aquesta diferència. Necessitem un segon número que digui **com de dispersos són els valors al voltant del centre**: una **mesura de dispersió**.

Al Bloc 4 hem vist el **rang** (màxim – mínim), la **variància** s^2 i la **desviació típica** s , i el teorema de **Txebixev**, que ens diu quina proporció de dades hi ha, com a mínim, dins de $\pm 2s$ i $\pm 3s$ de la mitjana. En aquesta activitat ho aplicarem a dues variables del nostre projecte:

- **Nits tropicals per estiu** (76 valors, una per any): molt variable.
- **TN de totes les nits d'estiu** (1.220 per dècada): molt més estable.

La pregunta de fons: *el clima de Nulles no només s'ha escalfat, sinó que també s'ha fet més “imprevisible”?*

Objectius

- Calcular el **rang**, la **variància** i la **desviació típica**, primer **a mà** (amb un exemple petit) i després amb R.
 - Entendre per què la `var()` i la `sd()` de R no coincideixen exactament amb les del curs (divisor n o $n-1$), i definir la nostra pròpia funció.
 - Comparar la dispersió entre **dècades**.
 - Aplicar **Txebixev** i comprovar-ne el compliment amb dades reals.
 - Fer-ho a Sheets amb MAX, MIN, VAR.P, DESVEST.P.
-

Part A — Treballem amb R

Primer fem tot el recorregut amb **R** (RStudio). A la Part B repetirem les mateixes operacions amb **Google Sheets**.

R · Pas 0 — Preparació

```
dades <- read.table("nulles_dades_climatiques_diaries.txt", skip = 11, header = TRUE, sep
= "\t")
estiu <- subset(dades, MES %in% c(6, 7, 8, 9))
estiu$tropical <- estiu$TN >= 20
estiu$decada <- (estiu$ANY %/% 10) * 10

anual <- aggregate(tropical ~ ANY, data = estiu, FUN = sum)
names(anual) <- c("ANY", "nits")
anual$decada <- (anual$ANY %/% 10) * 10
```

Explicació: com a l'Activitat 8: anual té una fila per any amb les nits tropicals de l'estiu, i estiu conté totes les nits de juny a setembre.

R · Pas 1 — El rang

```
x <- anual$nits
max(x) - min(x)
range(x)
```

Explicació: max() i min() donen el valor més gran i més petit; range() retorna els dos alhora (Activitat 3). Les nits tropicals per estiu van de **0 a 47**: rang = 47.

El rang és fàcil, però **depèn només de dos valors**, els extrems: un únic estiu atípic el canvia. Per això en busquem de millors.

R · Pas 2 — Variància i desviació típica, a mà

Fem el càlcul pas a pas amb un conjunt petit: les nits tropicals dels **sis estius de 2020-2025**: 21, 29, 36, 45, 28, 47.

```
y <- c(21, 29, 36, 45, 28, 47)
n <- length(y)
m <- mean(y)           # 34.33
desv <- y - m          # desviacions respecte a la mitjana
desv
desv^2                 # desviacions al quadrat
sum(desv^2)            # 523.33
var_n <- sum(desv^2) / n # variància: 87.22
sqrt(var_n)            # desviació típica: 9.34
```

Explicació, columna a columna:

Estiu	x_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
2020	21	-13,33	177,78
2021	29	-5,33	28,44
2022	36	1,67	2,78
2023	45	10,67	113,78
2024	28	-6,33	40,11
2025	47	12,67	160,44
Suma		0	523,33

- $y - m$: R resta m a **cada** element del vector (operació vectorial).
- Les desviacions sumen **0** (la mitjana és el punt d'equilibri); per això no podem usar-les directament: les elevem al **quadrat** perquè no es cancel·lin.
- desv^2 : l'operador $^$ és la potència.
- Variància $s^2 = \sum (x_i - \bar{x})^2 / n = 523,33 / 6 = 87,22$.
- Desviació típica $s = \sqrt{s^2} = 9,34$ nits tropicals. És en les **mateixes unitats** que les dades (nits), cosa que la variància (nits²) no té. Per això s'interpreta s com "una desviació habitual respecte a la mitjana".

Mini manual R — var() i sd() (divisor n-1)

R té funcions ja fetes, però **atenció**: var() i sd() divideixen per $n - 1$, no per n :

```
sd(y)      # 10.23 (divisor n-1)
```

Al Bloc 4 hem fet servir el divisor n . Per tant, **no coincideixen** (9,34 vs 10,23). Per obtenir la del curs, definim la nostra pròpia funció:

```
sd_n <- function(x) sqrt(mean((x - mean(x))^2))
sd_n(y) # 9.34
```

Explicació: function(x) ... crea una funció nova que rep un vector x . Dins fa $\text{mean}((x - \text{mean}(x))^2)$ (la mitjana dels quadrats de les desviacions, és a dir, la variància amb divisor n) i en treu l'arrel. A partir d'ara $\text{sd}_n()$ està disponible com qualsevol altra funció.

Quan n és gran la diferència desapareix: amb les 1.220 TN d'una dècada surt 2,650 vs 2,651. Per això, amb pocs valors (com els sis anys de la dècada de 2020) ens importa molt quina fórmula fem servir; amb molts, no.

R · Pas 3 — La dispersió de tot el conjunt

```
mean(x)      # 13.51
sd_n(x)      # 11.00
sd_n(x)^2    # variància: 121
```

La desviació típica (11 nits) és comparable a la mitjana (13,5): els estius són **molt diferents entre si**. Amb dades tan dispersides, la mitjana és una descripció pobre d'un estiu concret.

R · Pas 4 — Per dècades

```
aggregate(nits ~ decada, data = anual, FUN = sd_n)
aggregate(nits ~ decada, data = anual, FUN = function(v) max(v) - min(v))
```

Explicació: a FUN podem passar la nostra funció sd_n, o escriure'n una **al moment** sense nom (function(v) max(v) - min(v)). Resultats:


Dècada	Mitjana	Desv. típica (sd_n)	Rang
1950	9,9	7,24	0-23
1960	7,6	4,43	2-15
1970	3,2	3,63	0-9
1980	7,8	4,94	0-16
1990	13,1	7,62	2-28
2000	18,4	11,14	5-42
2010	22,1	5,56	12-31
2020 (6 anys)	34,3	9,34	21-47

Interpretació: la dispersió **no puja de manera ordenada** com la mitjana. La dècada del 2000 és la més dispersa (s = 11,1: va tenir estius de 5 i de 42 nits), mentre que la de 2010 és sorprenentment regular (s = 5,6: tots els estius entre 12 i 31). **Una mitjana alta no implica una dispersió alta** (ni baixa): són dues informacions independents.

R · Pas 5 — Veure la dispersió

```
mitjanes <- aggregate(nits ~ decada, data = anual, FUN = mean)

stripchart(nits ~ decada, data = anual, vertical = TRUE, method = "jitter",
           pch = 19, col = "steelblue",
           xlab = "Dècada", ylab = "Nits tropicals en un estiu",
           main = "Cada punt és un estiu")
points(1:8, mitjanes$nits, pch = 4, lwd = 3, cex = 2, col = "tomato")
```



Cada punt és un estiu

Explicació:

- `stripchart(y ~ grup, vertical = TRUE)`: dibuixa **cada dada com un punt**, en una columna per grup. Permet veure alhora el centre i la dispersió sense resumir res.
- `method = "jitter"`: **desplaça lleugerament** els punts en horitzontal perquè no se superposin quan hi ha valors repetits.
- `points(x, y, pch = 4)`: afegeix punts a un gràfic ja fet. Aquí, les mitjanes per dècada, com a creus vermelles (`pch = 4`; `cex` és la mida; `1:8` són les posicions de les vuit columnes).

Es veu clarament la columna del 2000 molt "allargada" i la del 2010 més "compacta".

R · Pas 6 — Txebixev amb dades reals

El teorema de Txebixev (Bloc 4) assegura que, **sigui quina sigui la distribució**, almenys el **75%** de les dades és dins de $\bar{x} \pm 2s$ i almenys el **89%** dins de $\bar{x} \pm 3s$. Comprovem-ho:

```
m <- mean(x); s <- sd_n(x)
c(m - 2 * s, m + 2 * s)      # [-8.49, 35.52]
mean(x >= m - 2 * s & x <= m + 2 * s) # 0.947 (72 de 76)
mean(x >= m - 3 * s & x <= m + 3 * s) # 0.987 (75 de 76)
```

Explicació: $x \geq a \ \& \ x \leq b$ dona TRUE per als valors dins de l'interval; `mean()` d'un vector lògic és la **proporció de TRUE** (Activitat 1).

Interpretació: el teorema es compleix amb molt de marge: $94,7\% \geq 75\%$ i $98,7\% \geq 89\%$. (Txebixev dona un mínim garantit; en distribucions “amb forma de campana” el percentatge real sol ser molt més alt.) Fixa't que l'interval $[-8,5; 35,5]$ inclou **valors negatius**, que són impossibles per a “nits”: és un senyal que aquesta distribució és molt asimètrica.

R · Pas 7 — La TN d'estiu: dispersió estable, mitjana creixent

Ara una variable molt menys dispersa: la temperatura mínima de **cada nit** d'estiu.

```
tn50 <- estiu$TN[estiu$decada == 1950]
tn10 <- estiu$TN[estiu$decada == 2010]
c(mean(tn50), sd_n(tn50)) # 16.35 2.65
c(mean(tn10), sd_n(tn10)) # 17.27 2.82

aggregate(TN ~ decada, data = estiu, FUN = sd_n)
```

Dècada	Mitjana de TN	Desv. típica
1950	16,35	2,65
1960	15,97	2,73
1970	15,41	2,56
1980	16,32	2,70
1990	16,43	2,87
2000	17,09	2,75
2010	17,27	2,82
2020	18,11	2,72

Interpretació: la mitjana puja uns 2,7 °C (de 15,4 a 18,1) però la desviació típica **es manté entre 2,6 i 2,9 °C**: la distribució s'ha **desplaçat** sense ensanxar-se. I això **explica per què les nits tropicals augmenten tan ràpid**: el llindar de 20 °C és a la cua alta de la distribució, i un petit desplaçament del centre afecta molt els valors de la cua.

Txebixev, també aquí:

```
mean(abs(tn50 - mean(tn50)) <= 2 * sd_n(tn50)) # 0.953
mean(abs(tn50 - mean(tn50)) <= 3 * sd_n(tn50)) # 0.999
```

(abs() és el valor absolut: $|x - \bar{x}| \leq 2s$ és una altra manera d'escriure $\bar{x} - 2s \leq x \leq \bar{x} + 2s$.) Surt 95,3% i 99,9%: molt per sobre dels mínims de Txebixev (75% i 89%), com era d'esperar en una distribució en forma de campana.

Part B — Treballem amb Google Sheets

Ara fem el mateix amb el full de càlcul, partint de les dades de l'Activitat 0.

Sheets · Pas 0 — Preparació

Com a l'Activitat 8: a la pestanya anual, els anys 1950–2025 a la columna A, les nits tropicals de cada estiu a la B (amb COMPTA.SI.CONJ) i la dècada a la C (=ENT(A2/10)*10).

Sheets · Pas 1 — Rang, variància i desviació típica

```
=MAX(B2:B77) - MIN(B2:B77)
=VAR.P(B2:B77)
=DESVEST.P(B2:B77)
```

Explicació: VAR.P i DESVEST.P (la **P** és de “població”) divideixen per **n**: són les que coincideixen amb el curs (11,00 i 121). Les versions VAR.S i DESVEST.S (o DESVEST) divideixen per **n-1**, com `sd()` de R. **Aquí, a Sheets, no cal definir cap funció:** només triar la que acaba en .P.

Per fer el càlcul “a mà”, tal com a R: escriu els sis valors del 2020–2025 a la columna E, a la F `=E2-MITJANA($E$2:$E$7)`, a la G `=F2^2`, i a sota `=SUMA(G2:G7)/6` (variància) i `=ARREL(G8)` (desviació típica). Has d’obtenir 87,22 i 9,34.

Sheets · Pas 2 — Per dècades

```
=DESVEST.P(FILTRA(B2:B77; C2:C77=2000))
```

FILTRA agafa només les nits tropicals dels anys de la dècada 2000, i DESVEST.P n’agafa la desviació (11,14). Fes la taula de les 8 dècades i un gràfic de columnes.

Sheets · Pas 3 — Txebixev

Amb la mitjana a H1 i la desviació a H2:

```
=COMPTA.SI.CONJ(B2:B77; ">="&(H1-2*H2); B2:B77; "<="&(H1+2*H2)) / COMPTA(B2:B77)
```

Explicació: `">="&(H1-2*H2)` construeix el criteri com a text (& enganxa textos i números). Dona $72/76 = 94,7\%$.

Sheets · Pas 4 — Què no es pot fer fàcilment

Sheets no té un gràfic “stripchart”. Es pot imitar amb un **gràfic de dispersió**: l’eix X és la dècada (columna C) i l’eix Y, les nits (columna B). Els punts d’una mateixa dècada es **superposen** en una línia vertical, sense “jitter”, però es veu igual l’amplada.

Per practicar

- Calcula `sd_n` de les nits tropicals de la dècada de **1970** (3,63) i la de **1950** (7,24). Les mitjanes (3,2 i 9,9) són molt diferents; i la dispersió *relativa* ($s / \bar{x}$)? Aquest quocient, el **coeficient de variació**, permet comparar dispersions de dades amb mitjanes diferents. (*Reptiu: quin és més variable en termes relatius, el 1970 o el 1950?*)
 - Per què, a la dècada de 2020 (només 6 anys), `sd()` de R (10,23) i `sd_n()` (9,34) difereixen tant? Fes la mateixa comparació amb tots els 76 estius.
 - Calcula el rang de la TN d'estiu de cada dècada. Té sentit comparar-los tenint en compte que la dècada de 2020 té 732 nits i les altres 1.220?
 - Comprova `Txebixev` amb la TN d'estiu de la dècada de 2010 (resultat esperat: 96,1% a $\pm 2s$ i 99,8% a $\pm 3s$).
-

Resum de l'activitat

- Hem calculat el **rang**, la **variància** ($\sum (x - \bar{x})^2 / n$) i la **desviació típica** a mà i amb R, i hem vist que `var()` i `sd()` de R divideixen per $n-1$: per això definim `sd_n()`.
- A Sheets, `VAR.P` i `DESVEST.P` coincideixen amb el curs.
- Hem comprovat que la **dispersió i la mitjana són informacions independents**: la dècada de 2010 té una mitjana alta i poca dispersió; la de 2000, una mitjana menor i molta dispersió.
- La TN d'estiu s'ha **desplaçat** (+2,7 °C des de la dècada de 1970) però **no s'ha ensanxat** ($s \approx 2,7$ °C): per això les nits tropicals augmenten tant.
- Hem comprovat el teorema de **Txebixev** amb dades reals.

Següent pas (Activitat 10): una altra manera de mesurar el centre i la dispersió sense dependre de la mitjana: els **percentils**, els **quartils** i el **diagrama de caixa (boxplot)**, per comparar dècades d'una ullada.