

Activitat 10 — Percentils, quartils i diagrama de caixa

Matemàtica Aplicada · Part pràctica — Bloc 5: Posició, forma i comparació de distribucions

Context

La mitjana i la desviació típica (Activitats 8 i 9) són molt útils, però tenen un punt feble: **es deixen influir pels valors extrems**. Els **percentils** ofereixen una altra manera, més robusta, de descriure una distribució: el **percentil p** és el valor que deixa per sota el $p\%$ de les dades. Els tres més importants són els **quartils**: Q1 (percentil 25), Q2 = mediana (percentil 50) i Q3 (percentil 75). La distància $Q3 - Q1$ és el **rang interquartílic** (IQR) i mesura la dispersió del 50% central de les dades.

Amb aquests cinc números (mínim, Q1, mediana, Q3, màxim) es construeix el **diagrama de caixa** (*boxplot*), el gràfic estrella per **comparar grups**. És exactament el que volem fer: comparar les **vuit dècades** de la temperatura mínima d'estiu a Nulles, i veure d'una ullada què ha passat amb **el llindar dels 20 °C** que defineix la nit tropical.

Aquesta activitat ens permetrà respondre preguntes concretes:

- *Quin percentil és els 20 °C a la dècada de 1950? I a la de 2020?*
- *Com han canviat Q1, la mediana i Q3 de dècada en dècada?*
- *Quins estius són "atípics" (outliers)?*

Objectius

- Calcular **percentils i quartils** amb `quantile()` seguint la definició del curs (`type = 1`).
- Interpretar un valor com a **posició** dins de la distribució (en quin percentil és el llindar de 20 °C).
- Construir i llegir un **boxplot**, calculant a mà els **límits** $Q1 - 1,5 \cdot IQR$ i $Q3 + 1,5 \cdot IQR$ per detectar valors atípics.
- Comparar **dècades** amb boxplots paral·lels.
- Fer-ho a Sheets amb `QUARTIL` i `PERCENTIL`, i conèixer les limitacions de Sheets amb el boxplot.

Part A — Treballem amb R

Primer fem tot el recorregut amb **R** (RStudio). A la Part B repetirem les mateixes operacions amb **Google Sheets**.

R · Pas 0 — Preparació

```
dades <- read.table("nulles_dades_climatiques_diaries.txt", skip = 11, header = TRUE, sep = "\t")
estiu <- subset(dades, MES %in% c(6, 7, 8, 9))
estiu$tropical <- estiu$TN >= 20
estiu$decada <- (estiu$ANY %/% 10) * 10

anual <- aggregate(tropical ~ ANY, data = estiu, FUN = sum)
names(anual) <- c("ANY", "nits")
anual$decada <- (anual$ANY %/% 10) * 10

tn50 <- estiu$TN[estiu$decada == 1950]
```

Explicació: com abans: estiu són totes les nits de juny a setembre, anual té una fila per estiu amb el nombre de nits tropicals, i tn50 és el vector de les 1.220 temperatures mínimes dels estius de 1950-1959.

R · Pas 1 — Percentils i quartils amb quantile()

```
quantile(tn50, probs = c(0.25, 0.5, 0.75), type = 1)
quantile(tn50, probs = 0.90, type = 1)
```

Explicació:

- `quantile(x, probs = ...)`: retorna els percentils indicats. probs són **proporcions** entre 0 i 1: 0.25 és el percentil 25, 0.9 el percentil 90.
- `type = 1`: R té **nou mètodes diferents** per calcular percentils (que només difereixen una mica quan les dades són poques). El **tipus 1** és el que correspon a la definició del Bloc 5: *el primer valor x_i tal que $N_i / N \geq p$* (la freqüència acumulada arriba al p). Si no l'indiquem, R fa servir el tipus 7 per defecte.
- Resultat, per a la dècada de 1950: **Q1 = 14,6; mediana = 16,5; Q3 = 18,3 °C**; el percentil 90 és 19,8 °C.

Lectura: el 25% de les nits d'estiu dels anys 50 va tenir una mínima de 14,6 °C o menys; el 50% central, entre 14,6 i 18,3 °C; i només un 10% va superar els 19,8 °C.

```
q <- quantile(tn50, c(0.25, 0.75), type = 1)
IQR(tn50, type = 1)      # 3.7
q[[2]] - q[[1]]          # el mateix: Q3 - Q1
```

Explicació: `IQR()` fa directament $Q3 - Q1$. Els dobles claudàtors `q[[1]]` agafen el primer element **sense el nom** (25%), de manera que es poden fer operacions netes.

R · Pas 2 — En quin percentil és el llindar de 20 °C?

Els quartils responen a “quin valor deixa el 25% per sota?”. Ara fem la pregunta **inversa**: “aquest valor, quin percentatge de dades deixa per sota?”

```
mean(tn50 < 20)      # 0.9189
f <- ecdf(tn50)
f(19.9)              # 0.9189
```

Explicació:

- `mean(tn50 < 20)`: el que hem fet des de l'Activitat 1: la proporció de TRUE d'un vector lògic. Dona la fracció de nits **no tropicals**.
- `ecdf(x)` (*empirical cumulative distribution function*) retorna una **funció**: la freqüència relativa acumulada F. `f(19.9)` és la fracció de dades $\leq 19,9$.

Així, a la dècada de 1950 el llindar de 20 °C es troba al **percentil 91,9**: només el 8,1% de les nits el superaven. Per a totes les dècades:

```
sapply(split(estiu$TN, estiu$decada), function(v) mean(v < 20))
```

Explicació: `split(x, grup)` **divideix** un vector en una llista de vectors, un per grup (aquí, una per dècada). `sapply(llibra, funció)` aplica la funció a **cada element** de la llista i en retorna els resultats juntats. És un aggregate més flexible.

Dècada	1950	1960	1970	1980	1990	2000	2010	2020
% de nits amb TN < 20	91,9	93,8	97,4	93,6	89,3	84,9	81,9	71,9

Interpretació: el llindar de 20 °C ha baixat del **percentil 92** al **percentil 72**. Dit d'una altra manera: de cada 100 nits d'estiu, a la dècada de 1950 en 8 es superaven 20 °C; a la de 2020, en **28**.

R · Pas 3 — El boxplot

```
boxplot(tn50, horizontal = TRUE, col = "lightblue",
        xlab = "Temperatura mínima d'estiu (°C)", main = "TN d'estiu, 1950-1959")
```

Com es llegeix un boxplot (Bloc 5):

- La **caixa** va de Q_1 a Q_3 (el 50% central de les dades); la seva amplada és l'IQR.
- La **línia gruixuda** dins la caixa és la **mediana**.
- Els **bigotis** arriben fins al valor més extrem que està dins dels **límits**:

$$\text{límit inferior} = Q_1 - 1,5 \cdot IQR, \quad \text{límit superior} = Q_3 + 1,5 \cdot IQR$$

- Els valors **fora** d'aquests límits es dibuixen com a **punts aïllats**: són els **valors atípics** (*outliers*).

Per als anys 50: $IQR = 3,7$, així el límit inferior és $14,6 - 1,5 \cdot 3,7 = \mathbf{9,05}$ i el superior, $18,3 + 1,5 \cdot 3,7 = \mathbf{23,85}$. Les nits amb $TN < 9,05$ són atípiques.


■ Mini manual R — límits a mà

```
Q1 <- q[[1]]; Q3 <- q[[2]]; iqr <- Q3 - Q1
c(Q1 - 1.5 * iqr, Q3 + 1.5 * iqr)      # 9.05 23.85
sum(tn50 < Q1 - 1.5 * iqr | tn50 > Q3 + 1.5 * iqr) # nombre d'atípics: 4
```

L'operador `|` és el “o” lògic (& és “i”). `sum()` d'un vector lògic compta els TRUE. Tindrem 4 nits atípiques (totes per sota: les més fredes de l'estiu).

R · Pas 4 — Comparar dècades: boxplots paral·lels

```
boxplot(TN ~ decada, data = estiu, horizontal = TRUE, col = "lightblue",
        xlab = "Temperatura mínima d'estiu (°C)", ylab = "Dècada",
        main = "TN d'estiu per dècada (Nulles)")
abline(v = 20, col = "red", lty = 2, lwd = 2)
```



Boxplot de TN d'estiu per dècada

Explicació:

- `boxplot(TN ~ decada, data = estiu)`: la mateixa notació de fórmula que a `aggregate()` (Activitat 4): "TN segons decada". Dibuixa **una caixa per a cada dècada**.
- `horizontal = TRUE`: caixes horitzontals (així les etiquetes de dècada es llegeixen millor).
- `abline(v = 20, ...)`: la línia vermella dels 20 °C.

Interpretació: la caixa **es desplaça cap a la dreta**, dècada a dècada, des dels anys 70 (la més freda). A la dècada de 2020 el **Q3 ja coincideix amb la línia dels 20 °C**: una quarta part de les nits d'estiu són tropicals. L'amplada de la caixa (IQR) és **gairebé constant** (3,5–4,0): la distribució es desplaça sense canviar de forma, tal com vam veure amb la desviació típica a l'Activitat 9.

Fixa't també que tots els atípics són **per sota**, mai per damunt: les nits d'estiu excepcionalment càlides no són un fenomen d'extrems, sinó de **desplaçament de tota la distribució**.

R · Pas 5 — Taula resum per dècada

Amb `split()` i `sapply()` construïm la taula dels cinc números i els límits per a totes les dècades d'un sol cop:

```
resum <- sapply(split(estiu$TN, estiu$decada), function(v) {  
  q <- quantile(v, c(0.25, 0.5, 0.75), type = 1)  
  iqr <- q[[3]] - q[[1]]  
  c(Q1 = q[[1]], mediana = q[[2]], Q3 = q[[3]], IQR = iqr,  
    LI = q[[1]] - 1.5 * iqr, LS = q[[3]] + 1.5 * iqr,  
    baixos = sum(v < q[[1]] - 1.5 * iqr),  
    alts = sum(v > q[[3]] + 1.5 * iqr),  
    p90 = quantile(v, 0.9, type = 1)[[1]])  
})  
t(round(resum, 2))
```

Explicació:

- `function(v) { ... }`: la funció que apliquem a cada dècada, escrita amb diverses línies entre claus `{ }`. Calcula quartils, IQR, límits i el nombre d'atípics de cada dècada, i ho retorna amb `c(...)`.
- `sapply` ho col·loca en una matriu amb una columna per dècada; `t()` la **transposa** (intercanvia files i columnes) perquè quedi una fila per dècada; `round(x, 2)` arrodoneix.

Has d'obtenir:

Dècada	Q1	Mediana	Q3	IQR	Límit inf.	Límit sup.	Atípics baixos	Atípics alts	P90
1950	14,6	16,5	18,3	3,7	9,05	23,85	4	0	19,8
1960	14,5	16,1	18,0	3,5	9,25	23,25	19	0	19,1
1970	13,8	15,6	17,3	3,5	8,55	22,55	7	0	18,4
1980	14,6	16,5	18,3	3,7	9,05	23,85	12	0	19,6
1990	14,5	16,7	18,5	4,0	8,50	24,50	5	0	20,1
2000	15,2	17,4	19,1	3,9	9,35	24,95	5	0	20,4
2010	15,3	17,5	19,3	4,0	9,30	25,30	5	0	20,8
2020	16,5	18,5	20,0	3,5	11,25	25,25	14	0	21,5

Interpretació: el **percentil 90** és un bon “indicador de nit càlida”: passa de 19,8 °C (anys 50) a 21,5 °C (anys 20) i **supera els 20 °C** per primer cop a la dècada de 1990. Dit d'una altra forma: a la dècada del 2020, el 10% de les nits més càlides de l'estiu són totes tropicals.


Nota sobre `boxplot()` i el tipus 1. El `boxplot()` de R calcula Q1 i Q3 amb un mètode lleugerament diferent (els *quarts de caixa* o *hinges*, que equivalen a `fivenum()`). Amb moltes dades la diferència és minúscula (per als anys 50 donen exactament 14,6 / 16,5 / 18,3), però amb pocs valors pot canviar una mica. Per això, per al curs, **els quartils que calculem amb `quantile(type = 1)` són els oficials**; el dibuix serveix per comparar.

R · Pas 6 — Boxplot de les nits tropicals per any

Fem el mateix amb el nombre de nits tropicals de cada estiu, comparant dècades:

```
boxplot(nits ~ decada, data = anual, col = "mistyrose",
        xlab = "Dècada", ylab = "Nits tropicals en un estiu",
        main = "Nits tropicals per any, per dècada")

q <- quantile(anual$nits, c(0.25, 0.5, 0.75), type = 1)
q                                     # 6 10 20
iqr <- q[[3]] - q[[1]]                # 14
LS <- q[[3]] + 1.5 * iqr               # 41
abline(h = LS, col = "red", lty = 2)
anual[anual$nits > LS, ]              # estius atípics
```



Boxplot de les nits tropicals per any

Explicació:

- `anual[anual$nits > LS, ]`: seleccionem les **files** de `anual` on es compleix la condició (el `,` final vol dir “totes les columnes”). Ens diu quins anys superen el límit.

Interpretació: amb els 76 estius, Q1 = 6, mediana = 10, Q3 = 20, IQR = 14, i el límit superior és **41**. Hi ha **tres estius atípics: 2003 (42 nits), 2023 (45) i 2025 (47)**. Dos són molt recents! El 2003, que a l'Activitat 8 semblava extrem, va ser un cas excepcional **llavors**; avui, el 2023 i el 2025 el superen.

Però fixa't: **dins de cada dècada**, el boxplot no marca cap atípic (els bigotis arriben fins a 42 i 47). **“Atípic” depèn del grup amb què es compara.** Un estiu amb 42 nits és extrem respecte al conjunt 1950–2025, però dins de la dècada de 2000 o 2020 és un cas més o menys esperable.

Els percentils també ens donen el “estiu normal i el dolent”: amb `quantile(anual$nits, c(0.1, 0.9), type = 1)` surt **2 i 28**: el 10% dels estius va tenir 2 nits o menys; el 10% més calorós, 28 o més.

Part B — Treballem amb Google Sheets

Ara fem el mateix amb el full de càlcul, partint de les dades de l'Activitat 0.

Sheets · Pas 0 — Preparació

Necessitarem les nits d'estiu d'una dècada. Com a l'Activitat 7:

```
=FILTRA(Dades!F2:F27760; (Dades!B2:B27760>=6) * (Dades!B2:B27760<=9) * (Dades!A2:A27760>=1950) * (Dades!A2:A27760<=1959))
```

Posa el resultat a una pestanya (tn1950); la columna A té 1.220 valors.

Sheets · Pas 1 — Quartils i percentils

```
=QUARTIL(tn1950!A:A; 1)
=QUARTIL(tn1950!A:A; 3)
=PERCENTIL(tn1950!A:A; 0,9)
```

Explicació:

- **QUARTIL**(dades; n): n = 0 (mínim), 1 (Q1), 2 (mediana), 3 (Q3) o 4 (màxim).
- **PERCENTIL**(dades; p): p entre 0 i 1 (0,9 en català és el percentil 90).
- **Compte:** Sheets **interpola** entre valors, com el tipus 7 de R, no fa servir “el primer x_i amb $F_i \geq p$ ”. Amb moltes dades (1.220) els resultats són pràcticament iguals als de R (14,6 / 16,5 / 18,3); amb poques (els 6 anys de 2020–2025) **poden diferir**.

L'IQR: =QUARTIL(...; 3) - QUARTIL(...; 1). Els límits: =Q1 - 1,5*IQR i =Q3 + 1,5*IQR.

Sheets · Pas 2 — En quin percentil és el llindar de 20 °C?

```
=COMPTA.SI(tn1950!A:A; "<20") / COMPTA(tn1950!A:A)
```

Explicació: COMPTA.SI compta les cel·les amb TN < 20, i COMPTA el total de números. Dona 0,9189 (91,9%). A Sheets també existeix RANG.PERCENTIL(dades; valor), que retorna el percentil d'un valor concret.

Sheets · Pas 3 — Taula resum per dècada

Fes una fila per dècada i, per a cada una, filtra amb FILTRA:

```
=QUARTIL(FILTRA(Dades!F2:F27760; (Dades!B2:B27760>=6)*(Dades!B2:B27760<=9)*(Dades!A2:A27760>=A2)*(Dades!A2:A27760<=A2+9)); 1)
```

(amb la dècada d'inici a A2: 1950, 1960...). Repeteix canviant l'1 final per 2 i 3 per a la mediana i Q3. Afegeix columnes per a l'IQR i els límits. Per a la dècada de 2020, que només té 6 anys, el límit superior de l'any (A2+9) no cal canviar-lo: simplement no hi ha dades posteriors al 2025.

Sheets · Pas 4 — El boxplot: el que Sheets no fa

Google Sheets no té un gràfic de caixa (boxplot). És una limitació real de l'eina. Hi ha dues sortides:

1. **El gràfic de “candlestick”** (*gràfic de canelobre*): **Inserir → Gràfic → Gràfic de canelobre**. Accepta quatre sèries (mínim, Q1, Q3, màxim) i dibuixa una caixa de Q1 a Q3 amb línies fins als extrems: **s’hi assembla molt**, però no marca la mediana ni calcula els atípics automàticament, i s’ha d’ordenar bé les columnes.
2. **Una taula amb format condicional** com la del Pas 3, on els valors de la mediana es poden comparar d’una ullada amb una **escala de colors (Format → Format condicional → Escala de colors)**.

Aquesta és una bona raó per fer servir R: el que és una línia en R (`boxplot(TN ~ decada, ...)`) és un petit projecte en Sheets.

Per practicar

- a. Calcula, amb `quantile(type = 1)`, el **Q1, la mediana i el Q3** de la TN d’estiu de la dècada de **2020** (resposta: 16,5 / 18,5 / 20,0). Què vol dir que $Q3 = 20$? Comprova-ho amb `mean(TN >= 20)`.
- b. Quin és el **percentil 5** i el **percentil 95** de la TN d’estiu del conjunt 1950–2025? Interpreta’ls.
- c. Fes un boxplot comparant només **dues dècades** (1950 i 2010) amb `boxplot(TN ~ decada, data = subset(estiu, decada %in% c(1950, 2010)))`. Quines diferències destaquen? (centre, amplada, atípics...)
- d. Fes els boxplots paral·lels de la **temperatura màxima d’estiu** (TX) per dècada. Es desplaça tant com TN?
- e. A la dècada de 2020, `median()` dona 32,5 nits tropicals per estiu, però `quantile(..., 0.5, type = 1)` en dona **29**. Per què? (*Pista: $n = 6$ és parell. Quin dels dos mètodes fa la mitjana dels dos valors centrals?*)

Resum de l’activitat

- Hem après a calcular **percentils** i **quantils** amb `quantile(type = 1)` (la definició del curs) i l’**IQR**.
- Hem interpretat un valor com a **posició**: el llindar de 20 °C ha passat del **percentil 92** (anys 50) al **percentil 72** (anys 20).
- Hem construït i llegit **boxplots**, calculat a mà els límits $Q1 - 1,5 \cdot IQR$ i $Q3 + 1,5 \cdot IQR$, i identificat els valors atípics.
- Hem comparat vuit dècades: la distribució de TN **es desplaça** cap amunt (la mediana puja de 16,5 a 18,5 °C) **sense canviar de forma** (l’IQR és gairebé constant).
- Hem vist que “atípic” depèn del conjunt amb què es compara: els estius amb 42, 45 i 47 nits tropicals (2003, 2023 i 2025) són atípics respecte a tota la sèrie.
- A Sheets, QUARTIL i PERCENTIL funcionen (amb interpolació), però **no hi ha boxplot natiu**.

Tancament del recorregut (Blocs 1-5): hem passat de les dades brutes a taules, gràfics, resums de centre, dispersió i posició, sempre sobre el mateix conjunt de dades. Tot plegat ens prepara per al següent bloc del curs: la **relació entre dues variables** (correlació i regressió), on ens preguntarem, per exemple, *quant augmenten les nits tropicals cada any?*