

Bloc 3 — Mesures de centralitat

Matemàtica Aplicada · Bloc d'estadística descriptiva

Per què necessitem mesures de centralitat?

Amb les taules de freqüències i els gràfics (Temes 1 i 2) descrivim tota la distribució de les dades. Sovint, però, interessa **resumir-la en un sol valor** que sigui representatiu.

Les tres mesures de centralitat més habituals són:

- La mitjana
- La mediana
- La moda

Cadascuna es calcula d'una manera diferent i és adequada per a un tipus de variable o un altre.

Quina mesura es pot calcular segons el tipus de variable?

Tipus de variable	Moda	Mediana	Mitjana
Nominal	Sí	No	No
Ordinal	Sí	Sí	No
Discreta	Sí	Sí	Sí
Contínua (agrupada)	Sí (interval modal)	Sí (interval medià)	Sí

La mitjana i la mediana exigeixen **valors numèrics** (o, en el cas de la mediana, com a mínim un **ordre**); la moda no exigeix res més que poder comptar freqüències.

La mitjana — definició

Donat un conjunt de n dades numèriques $x_1, x_2, \dots, x_n$, la mitjana aritmètica és:

$$\bar{x} = \frac{\sum x_i}{n}$$

És el valor que fem servir habitualment quan diem "la mitjana" en el llenguatge quotidià (per exemple, la mitjana de notes d'una classe).

Només té sentit per a variables **quantitatives**: cal poder sumar les dades.

La mitjana — amb una taula de freqüències

Si les dades ja estan agrupades en una taula, amb valors x_i i freqüències relatives f_i :

$$\bar{x} = \sum x_i \cdot f_i$$

Exemple: nombre de germans de 30 alumnes (Bloc 1, Exemple 3)

x_i (germans)	n_i	f_i
0	6	0,20
1	12	0,40
2	8	0,27
3	3	0,10
4	1	0,03

$$\bar{x} = 0 \cdot 0,20 + 1 \cdot 0,40 + 2 \cdot 0,27 + 3 \cdot 0,10 + 4 \cdot 0,03 = 1,37 \text{ germans}$$

La mitjana — dades agrupades en intervals

Quan les dades estan agrupades en intervals, se suposa que totes les dades de cada interval es concentren a la seva **marca de classe** (m_i):

$$\bar{x} = \sum m_i \cdot f_i$$

Exemple: alçades de 30 alumnes (Bloc 1, Exemple 4)

Interval	m_i	n_i	f_i
[155,160)	157,5	2	0,07
[160,165)	162,5	4	0,13
[165,170)	167,5	5	0,17
[170,175)	172,5	6	0,20
[175,180)	177,5	6	0,20
[180,185)	182,5	5	0,17
[185,190)	187,5	2	0,07

$$\bar{x} = 157,5 \cdot 0,07 + \dots + 187,5 \cdot 0,07 = 173 \text{ cm}$$

La mitjana — característiques

- Utilitza **totes** les dades: cada valor hi compta.
- És el "centre de gravetat" del conjunt: la suma de les desviacions respecte a ella és sempre zero, $\sum (x_i - \bar{x}) = 0$.
- És **molt sensible** a valors atípics o errors: una sola dada extrema pot desplaçar-la molt.
- No cal que coincideixi amb cap valor real de la variable (1,37 germans no és un valor possible, però és el que "equilibra" les dades).
- Només es pot calcular per a variables **quantitatives**.

La mediana — definició

Ordenades les dades de menor a major, la mediana és el valor que deixa el **50% per sota** i el **50% per sobre**.

- Si el nombre de dades n és **imparell**: la mediana és el valor central.
- Si n és **parell**: la mediana és la mitjana dels dos valors centrals.

A diferència de la mitjana, la mediana només necessita l'**ordre** de les dades, no el seu valor exacte.

La mediana — amb una taula de freqüències

Amb una taula de freqüències, la mediana és el primer valor x_i per al qual $\frac{N_i}{N} \geq 0,5$.

Exemple: nombre de germans de 30 alumnes

x_i (germans)	n_i	N_i	N_i/N
0	6	6	0,20
1	12	18	0,60
2	8	26	0,87

Com que $N_i/N = 0,20 < 0,5$ per a $x_i = 0$ i ja $0,60 \geq 0,5$ per a $x_i = 1$: **mediana = 1 germà.**

La mediana — també amb variables ordinals

Com que les categories ordinals tenen ordre encara que no siguin números, també s'hi pot calcular la mediana (però no la mitjana).

Exemple: valoració d'un servei per 25 usuaris (Bloc 1, Exemple 2)

Valoració	n_i	N_i	N_i/N
Molt malament	2	2	0,08
Malament	4	6	0,24
Regular	8	14	0,56
Bé	7	21	0,84

Mediana = "Regular" (és el primer valor amb $N_i/N \geq 0,5$).

La mediana — dades agrupades en intervals

Es localitza primer l'**interval medià**: el primer interval per al qual $N_i/N \geq 0,5$. En aquest bloc l'aproximem pel seu **punt mitjà**; més endavant, en parlar de percentils, afinarem el càlcul per interpolació.

Exemple: alçades de 30 alumnes

Interval	n_i	N_i	N_i/N
[165,170)	5	11	0,37
[170,175)	6	17	0,57

Interval medià = [170, 175) → mediana $\approx 172,5$ cm

La mediana — característiques

- Utilitza només l'**ordre** de les dades, no la seva magnitud exacta.
- És **poc sensible** a valors atípics o errors: encara que una dada sigui absurdament gran o petita, la mediana gairebé no es mou.
- Es pot calcular per a variables **quantitatives i qualitatives ordinals** (no per a nominals, que no tenen ordre).
- Com que ignora la magnitud exacta de les dades, no sempre aprofita tota la informació disponible.

La moda — definició

La moda és el valor (o categoria) amb **més freqüència**.

- Es pot calcular per a **qualsevol tipus de variable**, també la nominal.
- Pot no ser única: si dos o més valors comparteixen la freqüència màxima, la distribució és **bimodal** (o multimodal).

Exemple: mitjà de transport de 30 alumnes (Bloc 1, Exemple 1)

Mitjà de transport	n_i
Peu	9
Bus	9
Cotxe	6
Metro	4
Bicicleta	2

Moda bimodal: Peu i Bus (9 alumnes cadascun).

La moda — dades agrupades en intervals

Amb dades contínues agrupades, parlem d'**interval modal**: el (o els) interval(s) amb més freqüència.

Exemple: alçades de 30 alumnes

Interval	n_i
[165,170)	5
[170,175)	6
[175,180)	6
[180,185)	5

Intervals modals: [170, 175) i [175, 180), empatats a 6 alumnes.

A diferència de la mitjana i la mediana, aquí no obtenim un punt exacte, sinó l'interval (o intervals) on es concentren més dades.

La moda — característiques

- No es veu afectada per valors extrems: només compta freqüències.
- Es pot calcular per a variables nominals, ordinals, discretes i contínues (via interval modal).
- Pot no ser única (bimodal/multimodal) o, si totes les freqüències s'assemblen, pot no aportar gaire informació.
- Utilitza molt poca informació del conjunt de dades: només mira quin valor es repeteix més.

Comparant les tres mesures

Mesura	Utilitza	Sensibilitat a valors atípics	Es pot calcular a...
Mitjana	El valor numèric de cada dada	Alta	Variables quantitatives
Mediana	Només l'ordre de les dades	Baixa	Quantitatives i ordinals
Moda	Només la freqüència	Cap	Qualsevol tipus de variable

Recomanació pràctica: calcular sempre la mitjana i la mediana juntes. Si difereixen molt, és senyal de dades **asimètriques** o amb valors atípics.

Interpretació — l'efecte d'un valor atípic

Tornem al nombre de germans (Bloc 1, Exemple 3). Suposem que, per un error de transcripció, una de les dades "0" s'hagués registrat com "40":

	Sense error	Amb l'error
Mitjana	1,37 germans	2,70 germans (es dispara)
Mediana	1 germà	1 germà (no canvia)

Aquest exemple il·lustra per què **convé calcular sempre les dues**: la mediana ajuda a detectar quan la mitjana s'ha vist distorsionada per un error o un valor extrem.

Resum del bloc

1. Mitjana, mediana i moda resumeixen la distribució en un sol valor, cadascuna d'una manera diferent.
2. El tipus de variable (nominal, ordinal, discreta, contínua) determina quines es poden calcular.
3. La mitjana és sensible als valors atípics; la mediana i la moda, no.
4. Amb dades agrupades en intervals, la mediana i la moda són aproximades (interval medià / interval modal).

Següent pas: un únic valor de centralitat no diu res sobre com es **dispersen** les dades al seu voltant — això és el que veurem amb les **mesures de dispersió** (rang, desviació típica).