

Bloc 4 — Mesures de dispersió: la desviació típica

Matemàtica Aplicada · Bloc d'estadística descriptiva

Per què no n'hi ha prou amb un valor central?

Recordem l'exemple de "Què és l'Estadística?": una classe amb nota mitjana 5 pot donar-se de maneres molt diferents:

- La meitat treu un **10** i l'altra meitat un **0**
- **Tothom** treu exactament un **5**
- Les notes es reparteixen de manera **uniforme entre 0 i 10**

Mateixa mitjana, situacions completament diferents. Necessitem un número que mesuri **com de repartides** estan les dades al voltant del centre: això és el que fan les **mesures de dispersió**.

La variança — definició

Per a cada dada, calculem la seva desviació respecte a la mitjana: $x_i - \bar{x}$.

Ja sabem (Bloc 3) que la suma d'aquestes desviacions és sempre zero: $\sum (x_i - \bar{x}) = 0$. Per evitar que es cancel·lin, les **elevem al quadrat** abans de sumar-les.

La **variança** és la mitjana d'aquestes desviacions al quadrat:

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n}$$

Com més gran és s^2 , més allunyades estan, en conjunt, les dades de la mitjana.

La desviació típica — definició

La variança té un inconvenient: les seves unitats són el **quadrat** de les unitats originals (per exemple, cm^2 si les dades són en cm), cosa que la fa difícil d'interpretar.

Per tornar a les unitats originals, es defineix la **desviació típica** com l'arrel quadrada de la variança:

$$s = \sqrt{s^2} = \sqrt{\frac{\sum (x_i - \bar{x})^2}{n}}$$

La desviació típica és, doncs, un valor "típic" de com de lluny sol estar cada dada de la mitjana, **en les mateixes unitats que les dades**.

Càlcul amb una taula de freqüències

$$s^2 = \sum (x_i - \bar{x})^2 \cdot f_i$$

Exemple: nombre de germans de 30 alumnes ($\bar{x} = 1,37$)

x_i	n_i	f_i	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
0	6	0,20	-1,37	1,87
1	12	0,40	-0,37	0,13
2	8	0,27	0,63	0,40
3	3	0,10	1,63	2,67
4	1	0,03	2,63	6,93

$$s^2 = 1,87 \cdot 0,20 + 0,13 \cdot 0,40 + 0,40 \cdot 0,27 + 2,67 \cdot 0,10 + 6,93 \cdot 0,03 \approx 1,03$$

$$s = \sqrt{1,03} \approx \mathbf{1,02} \text{ germans}$$

Càlcul amb dades agrupades en intervals

$$s^2 = \sum (m_i - \bar{x})^2 \cdot f_i$$

Exemple: alçades de 30 alumnes ($\bar{x} = 173$ cm)

Interval	m_i	f_i	$m_i - \bar{x}$	$(m_i - \bar{x})^2$
[155,160)	157,5	0,07	-15,5	240,25
[160,165)	162,5	0,13	-10,5	110,25
[165,170)	167,5	0,17	-5,5	30,25
[170,175)	172,5	0,20	-0,5	0,25
[175,180)	177,5	0,20	4,5	20,25
[180,185)	182,5	0,17	9,5	90,25
[185,190)	187,5	0,07	14,5	210,25

$$s^2 \approx 68,92 \quad \Rightarrow \quad s = \sqrt{68,92} \approx \mathbf{8,3 \text{ cm}}$$

Característiques de la variança i la desviació típica

- Utilitzen **totes** les dades: cada valor hi compta (com la mitjana).
- Són **molt sensibles** a valors atípics: en elevar al quadrat, una dada molt allunyada pesa encara més que en la mitjana.
- s té les mateixes unitats que les dades; s^2 té unitats al quadrat (per això s és més fàcil d'interpretar).
- $s = 0$ únicament quan **totes** les dades són idèntiques (no hi ha cap dispersió).
- Només tenen sentit per a variables **quantitatives**.

Tornem a l'exemple inicial, ara amb números

Calculant la desviació típica de cada escenari (mitjana = 5 en tots tres):

Escenari	Desviació típica
Meitat treu 10, meitat treu 0	$s = 5$
Tothom treu un 5	$s = 0$
Notes uniformes entre 0 i 10	$s \approx 3,16$

La desviació típica **sí que distingeix** aquestes tres situacions, tot i que la mitjana és idèntica: com més gran és s , més "escampades" estan les dades.

Interpretant la desviació típica: la desigualtat de Txebixev

La desviació típica, per si sola, ja diu molt: sigui quina sigui la forma de la distribució (no cal que sigui simètrica ni "en forma de campana"), **la majoria de les dades s'acumulen a prop de la mitjana**, a una distància mesurada en desviacions típiques.

La desigualtat de Txebixev ho concreta amb un mínim garantit:

Distància a la mitjana	Percentatge mínim de dades
$\bar{x} \pm 2s$	almenys el 75%
$\bar{x} \pm 3s$	almenys el 89%

Val per a **qualsevol** conjunt de dades, sense excepcions.

Txebixev amb un exemple: les alçades

Amb $\bar{x} = 173$ cm i $s \approx 8,3$ cm:

- Interval $\bar{x} \pm 2s = [156,4, 189,6]$ cm $\rightarrow$ Txebixev garanteix que **com a mínim el 75%** dels alumnes hi són.
- Interval $\bar{x} \pm 3s = [148,1, 197,9]$ cm $\rightarrow$ **com a mínim el 89%**.

Si mirem les dades reals (alçades entre 158 i 187 cm), **el 100%** dels alumnes cauen dins del primer interval: Txebixev dona un mínim garantit, però a la pràctica la proporció real sol ser molt més alta.

Resum del bloc

1. La variança (s^2) i la desviació típica ($s = \sqrt{s^2}$) mesuren com es reparteixen les dades al voltant de la mitjana.
2. Es calculen a partir de les desviacions al quadrat: $\sum (x_i - \bar{x})^2$.
3. Són molt sensibles a valors atípics, igual que la mitjana amb la qual es calculen.
4. La desigualtat de Tchebixev permet interpretar s per a qualsevol distribució: la majoria de dades s'acumulen a prop de la mitjana.

Següent pas: al següent bloc treballarem els **percentils**, els **quartils** i el **diagrama de caixa**, que permeten descriure la dispersió a partir de l'ordre de les dades i detectar **valors atípics**.