

Bloc 5 — Percentils, quartils i el diagrama de caixa

Matemàtica Aplicada · Bloc d'estadística descriptiva

De la mediana als percentils

Al Bloc 3 vam definir la mediana com el valor que deixa el **50%** de les dades per sota i el **50%** per sobre.

Aquesta idea es pot generalitzar: el **percentil p** és el valor que deixa aproximadament el $p\%$ de les dades per sota seu.

- El **percentil 50** és, per definició, la **mediana**.
- Els percentils permeten localitzar qualsevol posició dins de la distribució, no només el centre.

Els quartils

Els **quartils** divideixen les dades ordenades en **quatre parts** amb (aproximadament) el mateix nombre de dades a cada part:

- Q_1 = percentil 25
- Q_2 = percentil 50 = **mediana**
- Q_3 = percentil 75

Entre Q_1 i Q_3 hi ha, doncs, aproximadament el **50% central** de les dades.

Càlcul dels quartils amb una taula de freqüències

De la mateixa manera que la mediana és el primer x_i amb $N_i/N \geq 0,5$, generalitzem la regla a qualsevol percentil p : el primer x_i amb $N_i/N \geq p$.

Exemple: nombre de germans de 30 alumnes

x_i	n_i	N_i	N_i/N
0	6	6	0,20
1	12	18	0,60
2	8	26	0,87

Q_1 : primer x_i amb $N_i/N \geq 0,25 \rightarrow Q_1 = 1$

Q_3 : primer x_i amb $N_i/N \geq 0,75 \rightarrow Q_3 = 2$

(la mediana, com ja sabíem, és $Q_2 = 1$)

El rang interquartílic

El rang interquartílic (IQR) és la diferència entre el tercer i el primer quartil:

$$IQR = Q_3 - Q_1$$

A diferència de la desviació típica, l'IQR **ignora el 25% de dades més petites i el 25% més grans**, i es queda només amb el 50% central. Per això és una mesura de dispersió **robusta**: uns pocs valors extrems gairebé no l'alteren.

Exemple (germans): $IQR = 2 - 1 = 1$

El diagrama de caixa (boxplot)

Representació gràfica construïda a partir dels quartils, pensada per mostrar la dispersió i detectar **valors atípics**:

1. Es dibuixa una caixa des de Q_1 fins a Q_3 , amb una línia a la mediana.
2. Es calculen uns **límits admissibles**:

$$LI = Q_1 - 1,5 \cdot IQR \quad LS = Q_3 + 1,5 \cdot IQR$$

3. Els **bigotis** arriben fins a la dada més allunyada que encara és dins de (LI, LS) .
4. Les dades fora de (LI, LS) es marquen com a **valors atípics**.

Diagrama de caixa — exemple


Nombre de germans: $Q_1 = 1$, mediana = 1, $Q_3 = 2$, $IQR = 1$

$$LI = 1 - 1,5 \cdot 1 = -0,5 \quad LS = 2 + 1,5 \cdot 1 = 3,5$$

Com que totes les dades van de 0 a 4, l'alumne amb **4 germans** queda fora de l'interval $(-0,5, 3,5)$: es marca com a **valor atípic**.

El gràfic també hi mostra la **mitjana** (1,37): és una mica més alta que la mediana (1), perquè l'atípic l'estira cap amunt — un bon recordatori del que vam veure al Bloc 4.

Diagrama de caixa — el gràfic



Interpretant la forma de la distribució

El boxplot no només mostra la dispersió: també revela si la distribució és **simètrica** o no.

- **Simètrica**: la mediana queda centrada dins la caixa, i els dos bigots tenen una longitud semblant.
- **Asimetria cap a la dreta** (cua de valors alts): la mediana s'apropa a Q_1 i/o el bigot superior és més llarg. La mitjana sol quedar **per sobre** de la mediana.
- **Asimetria cap a l'esquerra** (cua de valors baixos): la mediana s'apropa a Q_3 i/o el bigot inferior és més llarg. La mitjana sol quedar **per sota** de la mediana.

Comparar la posició de la mitjana i la mediana és una manera ràpida de detectar-ho.

Interpretant la forma — l'exemple dels germans

En el boxplot del nombre de germans hi coincideixen tres senyals:

- La mediana (1) coincideix amb Q_1 (1): el 25% de dades entre Q_1 i la mediana ocupa amplada zero.
- Hi ha un valor atípic només a la banda **alta** (4 germans), cap a la banda baixa.
- La mitjana (1,37) és més alta que la mediana (1): els valors alts l'estiren cap amunt.

Conclusió: la distribució té una **cua cap a la dreta** (asimetria positiva) — la majoria d'alumnes tenen pocs germans (0 o 1), però una minoria en té força més.

Comparant dos grups amb el diagrama de caixa


El boxplot és especialment útil per **comparar** la dispersió de diverses mostres o poblacions d'un cop d'ull.

Exemple: puntuació d'una prova d'aptitud (escala 0–20) en dos grups de 9 alumnes:

- Grup A: 5, 6, 6, 7, 7, 7, 8, 8, 9
- Grup B: 0, 5, 6, 7, 7, 7, 8, 9, 14

Ambdós grups tenen la **mateixa mediana (7)** i la **mateixa mitjana (7)**, però...

Comparant dos grups — el gràfic



- Grup A: $Q_1 = 6$, $Q_3 = 8 \rightarrow IQR = 2$, sense valors atípics.
- Grup B: $Q_1 = 5,5$, $Q_3 = 8,5 \rightarrow IQR = 3$, amb **dos valors atípics** (0 i 14).

Interpretació de la comparació

Quan comparem diagrames de caixa de diversos grups, cal fixar-se en:

- **Posició de la mediana i la mitjana:** quin grup té valors, en general, més alts o més baixos.
- **Amplada de la caixa (IQR):** quin grup té més dispersió en el 50% central.
- **Longitud dels bigotis:** com de repartida és la resta de les dades.
- **Presència i nombre de valors atípics.**
- **Forma:** en aquest cas, els dos grups són prou **simètrics** (mediana centrada, bigotis i atípics equilibrats a banda i banda) — a diferència de l'exemple dels germans, aquí l'asimetria no és el que els distingeix.

En el nostre exemple: **mateixa tendència central (mediana i mitjana = 7 en tots dos grups)**, però el Grup B és clarament **més variable** i presenta alumnes amb resultats molt allunyats de la resta — un cas clar en què la mitjana i la mediana, per si soles, amaguen diferències importants.

Resum del bloc

1. Els **percentils** generalitzen la idea de mediana a qualsevol posició de la distribució; els **quartils** (Q_1, Q_2, Q_3) en són el cas particular que divideix les dades en quatre parts.
2. El **rang interquartílic** ($Q_3 - Q_1$) és una mesura de dispersió robusta, poc afectada per valors extrems.
3. El **diagrama de caixa** representa gràficament mediana, quartils, bigotis i valors atípics, i és una eina molt útil per **comparar** mostres o poblacions.
4. Els **valors atípics** es defineixen a partir dels límits $Q_1 - 1,5 \cdot IQR$ i $Q_3 + 1,5 \cdot IQR$.
5. La **forma** de la caixa i dels bigotis (i la posició relativa de mitjana i mediana) permet detectar si una distribució és simètrica o asimètrica.